# Informação Funcional Quântica no Espaço do Problema

Reformulação para Otimização Combinatória
via Maximum Independent Set

Projeto QFI
Rafaella Somoza

**Mudança conceitual principal**
Nas versões anteriores deste documento, a distribuição de probabilidade utilizada na informação funcional era obtida principalmente a partir do próprio circuito, por exemplo por meio da distribuição de fidelidades.
Nesta reformulação, separamos explicitamente duas ideias:

$$\textbf{Funcionalidade} \longrightarrow \textbf{espaço do problema}$$

$$\textbf{Circuito quântico} \longrightarrow \textbf{mecanismo que redistribui probabilidade}$$

**Ideia central:** a informação funcional pertence à paisagem do problema; o circuito determina o quanto regiões funcionais dessa paisagem são acessadas, amplificadas ou concentradas.

## Sumário

**1 Hierarquia conceitual da reformulação** **3**

**2 Reformulação em torno do Maximum Independent Set** **3**

2.1 Espaço do problema . . . . . 3

2.2 O Hamiltoniano como paisagem funcional . . . . . 4

2.3 Informação funcional intrínseca do problema . . . . . 4

2.4 Informação funcional de cada estado . . . . . 5

**3 Paisagem do problema e distribuição do circuito** **5**

**4 Amplificação funcional** **6**

**5 Informação funcional intermediária** **7**

**6 Viabilidade e qualidade** **8**

6.1 Viabilidade . . . . . 8

6.2 Qualidade condicional à viabilidade . . . . . 9
6.3 Composição . . . . . 9

**7 Comparação com a literatura** **10**
7.1 Continuidade com Hazen . . . . . 10
7.2 Diferença em relação à QFI original . . . . . 10
7.3 Pontos de Wong et al. (2023) . . . . . 10
7.4 Conexão complementar com FID . . . . . 12

**8 Protótipo numérico** **12**
8.1 QAOA com parâmetros arbitrários . . . . . 13
8.2 QAOA com parâmetros otimizados . . . . . 13

**9 Perguntas de pesquisa** **14**

# 1. Hierarquia conceitual da reformulação

**Problema $G$**

↓

**Espaço de soluções $\Omega$**

↓

**Hamiltoniano $H(x)$**

↓

**Paisagem funcional**

↓

**Informação funcional intrínseca $I_F(x)$**

↓

**Distribuição do circuito $p_d(x)$**

↓

**Informação funcional intermediária $\langle I_F \rangle_d$**

↓

**Amplificação / ganho funcional**

↓

**Comparação entre profundidades**

**A informação funcional pertence à paisagem do problema; o circuito quântico determina o quão fortemente essa informação é acessada, amplificada ou concentrada ao longo da evolução.**

# 2. Reformulação em torno do Maximum Independent Set

## 2.1 Espaço do problema

Seja

$$G = (V, E)$$

um grafo com

$$n = |V|$$

vértices.

Cada bitstring da base computacional

$$x = (x_1, \ldots, x_n) \in \{0, 1\}^n$$

representa um subconjunto candidato de vértices.

O espaço completo do problema é:

**Espaço de soluções**

$$\boxed{\Omega = \{0,1\}^n}$$

e portanto

$$\boxed{|\Omega| = 2^n}$$

## 2.2 O Hamiltoniano como paisagem funcional

Em vez de utilizar apenas uma função de qualidade abstrata, usamos o Hamiltoniano do MIS como paisagem funcional primária:

**Hamiltoniano do MIS**

$$\boxed{H(x) = A \sum_{(i,j)\in E} x_i x_j - B \sum_i x_i}$$

O primeiro termo penaliza a seleção simultânea de vértices adjacentes.

O segundo termo recompensa subconjuntos maiores.

Assim:

- configurações inválidas tendem a apresentar maior energia;
- independent sets válidos apresentam menor energia;
- entre soluções válidas, conjuntos maiores tendem a apresentar energia ainda menor.

Escolhendo uma penalização suficientemente forte, por exemplo $A \gg B$, evita-se que o ganho obtido pela seleção de vértices compense a violação das restrições de independência.

## 2.3 Informação funcional intrínseca do problema

Para um limiar de energia $h$, definimos o conjunto:

$$F_h = \{x \in \Omega : H(x) \leq h\}.$$

Esse conjunto contém todas as soluções que são pelo menos tão funcionais quanto o nível definido por $h$.

A probabilidade correspondente no espaço uniforme do problema é:

$$P_{\text{problem}}(h) = \frac{|F_h|}{|\Omega|} = \frac{|F_h|}{2^n}.$$

**Informação funcional no limiar $h$**

$$\boxed{I_F(h) = -\log_2 P_{\text{problem}}(h)}$$

ou, explicitamente,

$$\boxed{I_F(h) = -\log_2 \left[ \frac{|\{x \in \Omega : H(x) \leq h\}|}{2^n} \right]}$$

**Interpretação:** essa quantidade mede o quanto de informação está associado a encontrar, por amostragem uniforme do espaço do problema, uma solução pelo menos tão funcional quanto o limiar $h$.

A principal diferença em relação à formulação anterior é que agora a origem da distribuição de probabilidade está explicitamente definida: ela vem do espaço do problema.

### 2.4 Informação funcional de cada estado

Em vez de trabalhar apenas com um limiar fixo, podemos atribuir uma informação funcional intrínseca a cada estado candidato $x$.

**Informação funcional de uma solução $x$**

$$\boxed{I_F(x) = -\log_2 \left[ \frac{|\{y \in \Omega : H(y) \leq H(x)\}|}{|\Omega|} \right]}$$

solução comum / baixa qualidade
$\downarrow$
baixa informação funcional

solução rara / alta qualidade
$\downarrow$
alta informação funcional

Os melhores estados de MIS ocupam regiões de maior informação funcional na paisagem do problema.

Esta quantidade é um dos elementos centrais da reformulação.

## 3. Paisagem do problema e distribuição do circuito

Considere um circuito parametrizado

$$U_C = U(\boldsymbol{\theta}).$$

O estado final produzido pelo circuito é:

$$|\psi_C\rangle = U_C|0\rangle^{\otimes n} = \sum_x \alpha_x |x\rangle.$$

A probabilidade de medir $x$ é:

$$\boxed{p_C(x) = |\alpha_x|^2}$$

A distinção fundamental é:

| **PROBLEMA** | **CIRCUITO** |
|---|---|
| Define a qualidade | Define a probabilidade |
| $H(x)$ | $p_C(x) = \lvert\alpha_x\rvert^2$ |
| $I_F(x)$ | $p_d(x)$ |
| Quão rara/funcional é a solução? | Quão provável é observar a solução? |

O circuito **não redefine a funcionalidade**.
Ele apenas redistribui massa de probabilidade sobre uma paisagem funcional previamente definida pelo problema.

## 4. Amplificação funcional

Para um limiar funcional $h$, definimos a probabilidade de sucesso sob o circuito:

$$P_C(h) = \sum_{x:H(x)\leq h} p_C(x).$$

A comparação com a probabilidade uniforme do espaço do problema define a amplificação funcional:

**Amplificação funcional**

$$\boxed{A_F(C,h) = \frac{P_C(h)}{P_{\text{problem}}(h)}}$$

A interpretação é:

$$A_F = 1 \quad \Rightarrow \quad \text{equivalente à amostragem uniforme}$$

$$A_F > 1 \quad \Rightarrow \quad \text{concentração de probabilidade em estados funcionais}$$

$$A_F < 1 \quad \Rightarrow \quad \text{menor concentração do que a referência uniforme}$$

Na escala logarítmica, definimos o ganho funcional:

**Ganho funcional**

$$\boxed{G_F(C,h) = \log_2 A_F(C,h)}$$

Equivalentemente,

$$\boxed{G_F(C,h) = I_F(h \mid \mathcal{C}_{\text{prob}}) - I_F^C(h)}$$

onde

$$I_F^C(h) = -\log_2 P_C(h).$$

Assim:

$$G_F > 0$$

indica que o circuito tornou soluções da região funcional considerada mais prováveis do que seriam sob amostragem uniforme.

O ganho funcional é uma medida derivada útil, mas não substitui a definição intrínseca de informação funcional no espaço do problema.

## 5. Informação funcional intermediária

Esta é a parte central da reformulação para o objetivo original do projeto: acompanhar a informação funcional ao longo da evolução ou profundidade do circuito.

Para um grafo e Hamiltoniano fixos,

$$I_F(x)$$

permanece fixo.

O que muda conforme a profundidade $d$ é:

$$p_d(x).$$

Portanto, definimos:

**Métrica principal para QFI intermediária**

$$\boxed{\langle I_F \rangle_d = \sum_{x \in \Omega} p_d(x)\, I_F(x)}$$

Essa quantidade representa a informação funcional média acessada pela distribuição do circuito naquela profundidade.

Podemos acompanhar:

$$\langle I_F \rangle_0 \longrightarrow \langle I_F \rangle_1 \longrightarrow \langle I_F \rangle_2 \longrightarrow \cdots \longrightarrow \langle I_F \rangle_d.$$

**Pergunta central**

*Como a distribuição de probabilidade do circuito migra, camada por camada, para regiões de maior informação funcional?*

Também podemos definir:

**Variação da informação funcional**

Ganho acumulado:

$$\boxed{\Delta I_d = \langle I_F \rangle_d - \langle I_F \rangle_0}$$

Ganho entre profundidades consecutivas:

$$\boxed{\delta I_d = \langle I_F \rangle_d - \langle I_F \rangle_{d-1}}$$

Essas medidas permitem investigar:

- em que momento a informação funcional começa a crescer;
- quais camadas produzem os maiores aumentos;
- se existem camadas que reduzem a informação funcional;
- se o circuito aprende primeiro viabilidade e depois qualidade.

Para um grafo e Hamiltoniano fixos, a paisagem $I_F(x)$ não precisa mudar durante o circuito.
O objeto dinâmico é a distribuição:

$$p_d(x).$$

Logo, a informação funcional intermediária é obtida avaliando como essa distribuição evolui sobre uma paisagem funcional fixa.

## 6. Viabilidade e qualidade

Para MIS, é útil separar dois níveis de funcionalidade:

1. encontrar uma solução válida;
2. encontrar uma solução de alta qualidade entre as válidas.

### 6.1 Viabilidade

Definimos:

$$\Omega_{\text{IS}} = \{x : x_i x_j = 0, \forall (i,j) \in E\}.$$

A informação associada à raridade de obter qualquer independent set válido é:

**Informação de viabilidade**

$$\boxed{I_{\text{valid}} = -\log_2 \left[ \frac{|\Omega_{\text{IS}}|}{2^n} \right]}$$

## 6.2 Qualidade condicional à viabilidade

Para um limiar de tamanho $k$, definimos:

$$F_k = \{x \in \Omega_{\text{IS}} : |x| \geq k\}.$$

A informação funcional associada à qualidade, dado que a solução já é válida, é:

**Informação de qualidade**

$$\boxed{I_{\text{quality}}(k \mid \text{IS}) = -\log_2 \left[ \frac{|F_k|}{|\Omega_{\text{IS}}|} \right]}$$

## 6.3 Composição

As duas quantidades se compõem exatamente:

**Composição da informação funcional**

$$\boxed{I_{\text{total}}(k) = I_{\text{valid}} + I_{\text{quality}}(k \mid \text{IS})}$$

**encontrar uma solução válida**
+
**encontrar uma solução boa entre as válidas**

Isso ocorre porque:

$$-\log_2 \left( \frac{|\Omega_{\text{IS}}|}{2^n} \right) - \log_2 \left( \frac{|F_k|}{|\Omega_{\text{IS}}|} \right) = -\log_2 \left( \frac{|F_k|}{2^n} \right).$$

Essa decomposição permite distinguir:

**satisfazer restrições**

↓

**otimizar a qualidade**

Um circuito pode aumentar rapidamente a probabilidade de produzir soluções válidas sem necessariamente melhorar a qualidade dessas soluções.

# 7. Comparação com a literatura

| | **Hazen et al.** | **QFI original** | **Reformulação MIS** |
|---|---|---|---|
| **Espaço** | Configurações do sistema | Circuitos | Soluções $\Omega$ |
| **Função** | Grau $E_x$ | Fidelidade | Hamiltoniano $H(x)$ |
| **Raridade** | $M(E_x)/N$ | Ensemble de circuitos | $\lvert\{y : H(y) \leq H(x)\}\rvert/2^n$ |
| **Dinâmica** | Seleção | Evolução de circuitos | Redistribuição de $p_d(x)$ |
| **Objeto intermediário** | — | Fidelidade durante evolução | $\langle I_F \rangle_d$ |

## 7.1 Continuidade com Hazen

A formulação clássica é:

$$I(E_x) = -\log_2 \left[ \frac{M(E_x)}{N} \right].$$

Na reformulação MIS:

$$N \longrightarrow 2^n$$

e:

$$M(E_x) \longrightarrow |\{y : H(y) \leq H(x)\}|.$$

Assim, a estrutura da informação funcional clássica é preservada.

## 7.2 Diferença em relação à QFI original

Na formulação original baseada em fidelidade, a função está associada ao comportamento do circuito, por exemplo sua capacidade de aproximar um estado-alvo.

Na reformulação para MIS:

- a função pertence ao espaço de soluções;
- o Hamiltoniano define a qualidade;
- a raridade é medida no espaço de soluções;
- o circuito altera apenas a probabilidade de acessar essas soluções.

Os termos “QFI no espaço do problema” e “informação funcional no espaço de soluções” são utilizados aqui como propostas conceituais, e não como terminologia já estabelecida.

## 7.3 Pontos de Wong et al. (2023)

1. **Contextualidade**

A informação funcional depende de um sistema, de uma função e de um contexto.

Para MIS, podemos escrever:

$$I_F(x \mid G).$$

A mesma bitstring pode ser uma boa solução em um grafo e uma solução inválida em outro.

2. **Distribuição funcional**

   Calcular informação funcional exige conhecer a distribuição dos graus de função no espaço relevante.

   O MIS fornece um ambiente controlado porque:

$$\Omega = \{0,1\}^n$$

   é conhecido explicitamente.

   Para $n$ pequeno, pode ser enumerado exatamente; para $n$ maior, pode ser estimado por amostragem ou contagem aproximada.

3. **Seleção**

   Um mecanismo que favorece configurações com maior função desloca o sistema para regiões de maior informação funcional.

   No cenário quântico:

$$\text{bitstrings} \rightarrow \text{configurações}$$

$$\text{Hamiltoniano} \rightarrow \text{grau de função}$$

$$\text{circuito} \rightarrow \text{mecanismo de exploração / seleção}$$

4. **Interpretação temporal**

   Para $G$ e $H$ fixos:

$$I_F(x \mid G)$$

   permanece fixo.

   O que muda é:

$$p_d(x).$$

   Logo:

$$\boxed{\langle I_F \rangle_d = \sum_x p_d(x) I_F(x)}$$

   é o objeto natural para acompanhar a evolução intermediária.

### 7.4 Conexão complementar com FID

Functional Information Decomposition (FID) deve ser tratado como um framework complementar.

Enquanto a abordagem de Hazen/Wong mede a **raridade associada à função**, FID analisa como diferentes inputs contribuem individualmente ou de forma sinergística para um output.

Uma aplicação futura poderia utilizar:

qubits / variáveis do grafo

↓

inputs

qualidade / viabilidade / Hamiltoniano

↓

output

Isso permitiria investigar se a funcionalidade depende principalmente de componentes individuais ou de interações conjuntas.

## 8. Protótipo numérico

Foi implementado um protótipo sobre um grafo aleatório com:

$$n = 8$$

vértices e:

$$|E| = 15.$$

Foi utilizado um modelo Erdős–Rényi com:

$$p = 0{,}35, \qquad A = 2, \qquad B = 1.$$

Os resultados foram:

| **Métrica** | **Resultado** |
|---|---|
| Independent sets válidos | 26 de 256 |
| Proporção válida | 10,16% |
| Tamanho do MIS | 3 |
| $I_{\text{valid}}$ | 3,300 bits |
| $I_{\text{quality}}(3 \mid \text{IS})$ | 2,700 bits |
| $I_{\text{total}}(3)$ | 6,000 bits |
| $I_F(h^*)$ | 6,000 bits |

A identidade:

$$I_{\text{total}} = I_{\text{valid}} + I_{\text{quality}}$$

foi confirmada numericamente.

## 8.1 QAOA com parâmetros arbitrários

Um circuito QAOA com parâmetros escolhidos manualmente mostrou um comportamento importante.

A probabilidade de viabilidade aumentou aproximadamente de:

$$0{,}28 \quad \longrightarrow \quad 0{,}95.$$

Entretanto, o ganho funcional no melhor limiar piorou de:

$$+0{,}81 \quad \longrightarrow \quad -7{,}67 \text{ bits.}$$

Ao mesmo tempo, o tamanho médio do conjunto caiu de:

$$3{,}26 \quad \longrightarrow \quad 0{,}43.$$

**Interpretação**

O circuito aprendeu a produzir soluções válidas, mas passou a favorecer soluções triviais e pequenas.
Isso mostra que:

$$\text{viabilidade} \neq \text{otimalidade}.$$

## 8.2 QAOA com parâmetros otimizados

Após otimização por COBYLA de um circuito QAOA com profundidade $p = 4$, os estados intermediários apresentaram:

| $d$ | $\langle I_F \rangle_d$ | $P_d$(válido) | $E_d[\lvert x \rvert]$ | $G_F$ |
|---|---|---|---|---|
| 1 | 2,587 | 0,316 | 3,08 | 2,92 |
| 2 | 2,973 | 0,473 | 2,99 | 3,69 |
| 3 | 3,245 | 0,551 | 2,86 | 4,02 |
| 4 | 3,334 | 0,551 | 2,89 | 4,05 |

Com parâmetros otimizados, o valor *final* de $\langle I_F \rangle_d$ e de $G_F(C_d, h^*)$ é o mais alto da trajetória. Entretanto, **não** afirmamos crescimento monotônico com a profundidade: em testes com 4 sementes, truncar um circuito $p = 3$ treinado conjuntamente produziu valores intermediários não monótonos em 3 das 4 sementes (a camada final foi sempre a melhor). Isso é esperado, pois os parâmetros foram otimizados para a profundidade final, e não para cada camada intermediária.

**Definição de estado intermediário (decisão metodológica).** Adotamos como definição *principal* treinar circuitos separados com $p = 1, 2, 3$, cada um otimizado para a sua própria profundidade (como já feito no código do David). O truncamento de um circuito profundo treinado fica como observação *secundária*.

**Questão de pesquisa.** A mesma métrica $\langle I_F \rangle$, calculada com a distribuição $p_d(x)$ de algoritmos clássicos (EDAs e algoritmos genéticos, com mesmo orçamento de avaliações), permite comparar a capacidade de explorar regiões funcionais de forma justa?

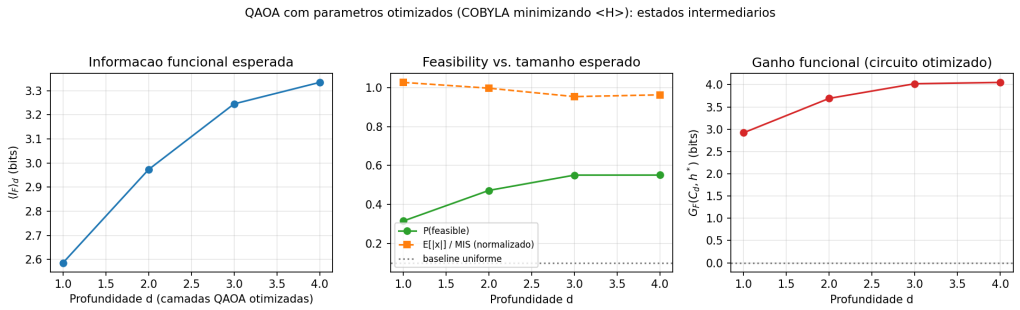



Figura 1: Informação funcional esperada, viabilidade, tamanho esperado e ganho funcional ao longo da profundidade.

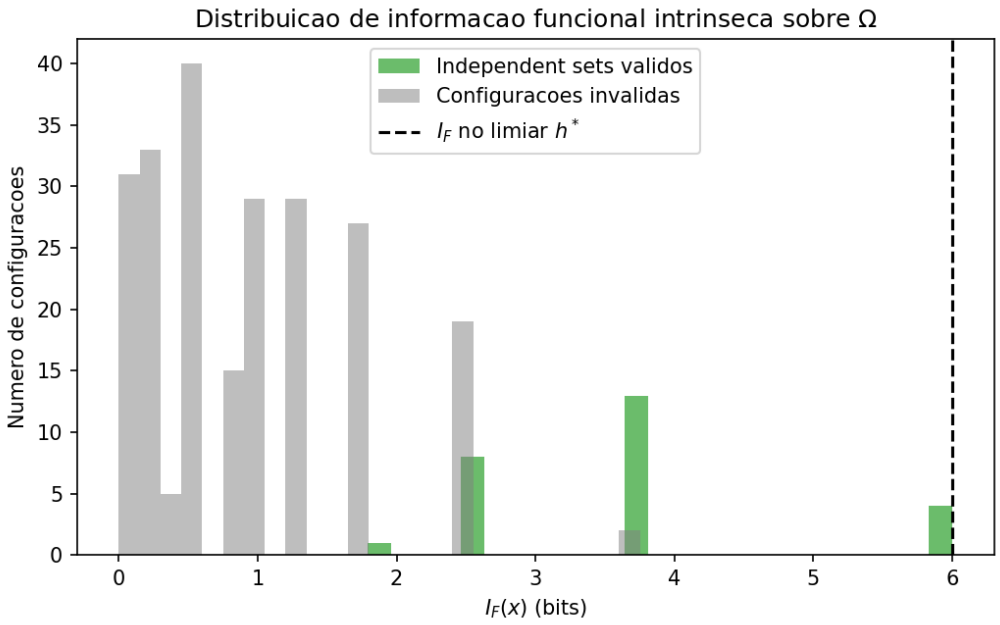



Figura 2: Distribuição de $I_F(x)$ sobre o espaço de soluções, separada por viabilidade.

## 9. Perguntas de pesquisa

1. Onde a informação funcional deve ser definida: no espaço dos circuitos ou no espaço do problema?
2. Qual distribuição de probabilidade deve ser usada na fórmula de informação funcional?
3. O que permanece fixo e o que muda durante a evolução do circuito?

4. É possível atribuir informação funcional a cada solução candidata?
5. A informação funcional esperada pode caracterizar estados intermediários?
6. Viabilidade emerge antes de otimalidade?
7. O circuito pode ser interpretado como amplificador de regiões de alta informação funcional?
8. $\langle I_F \rangle$ revela informações que $\langle H \rangle$ sozinho não revela?
9. A métrica pode ser validada sistematicamente em instâncias pequenas de MIS?

## Proveniência das equações

**Literatura estabelecida**

Hazen et al.:

$$\boxed{I(E_x) = -\log_2 \left[ \frac{M(E_x)}{N} \right]}$$

**Adaptação direta para MIS**

$$\boxed{I_F(x) = -\log_2 \left[ \frac{|\{y : H(y) \leq H(x)\}|}{2^n} \right]}$$

Aplicação estrutural da informação funcional clássica ao espaço de soluções do MIS.

**Métricas propostas nesta reformulação**

$$A_F(C, h)$$

$$G_F(C, h)$$

$$\boxed{\langle I_F \rangle_d = \sum_x p_d(x) I_F(x)}$$

$$\Delta I_d = \langle I_F \rangle_d - \langle I_F \rangle_0$$

$$\delta I_d = \langle I_F \rangle_d - \langle I_F \rangle_{d-1}$$

## Síntese

**Problema**
define

$$I_F(x)$$

**Circuito**
define

$$p_d(x)$$

**Estados intermediários**
são caracterizados por

$$\boxed{\langle I_F \rangle_d = \sum_x p_d(x) I_F(x)}$$

**A paisagem funcional permanece fixa.**
**A distribuição do circuito evolui sobre ela.**

## Referências


- Hazen, R. M., Griffin, P. L., Carothers, J. M., & Szostak, J. W. (2007). *Functional information and the emergence of biocomplexity.* PNAS, 104(suppl. 1), 8574–8581.
- Wong, M. L. et al. (2023). *On the roles of function and selection in evolving systems.* PNAS, 120(43), e2310223120.
- Bohm, C., Ragusa, V. R., Hintze, A., Ofria, C., Dolson, E., & Adami, C. (2026). *Functional Information Decomposition: A First-Principles Approach to Analyzing Functional Relationships.* arXiv:2509.18522v3.
- Pasti, R., & Krause, J. (2025). *Quantum Functional Information through the Evolution of Random Circuits.* arXiv:2509.11409.
- Szostak, J. W. (2003). *Functional information: Molecular messages.* Nature, 423, 689.